AVALIAÇÃO DE TÉCNICAS DE EXTRAÇÃO DE CARACTERÍSTICAS PARA RECONHECIMENTO DE USUÁRIOS PELA IMPRESSÃO DIGITAL

Thiago Fernandes Dias[1,2], **Paulo Henrique Pisani**[1] (Orientador), **Francisco de Assis Zampirolli**[1] (Coorientador)
[1]Centro de Matemática, Computação e Cognição (CMCC) – Universidade Federal do ABC (UFABC)
[2]Bolsista de Iniciação Científica (CNPq) · Santo André – SP, Brasil
fernandes.thiago@aluno.ufabc.edu.br, paulo.pisani@ufabc.edu.br, f.zampirolli@ufabc.edu.br

OBJETIVOS

Este projeto tem como objetivo central **avaliar e comparar o desempenho de diferentes técnicas de extração de características para o reconhecimento de usuários pela impressão digital**.

INTRODUÇÃO

A biometria por impressões digitais baseia-se na singularidade e perenidade dos padrões de cristas e vales na epiderme das pontas dos dedos [4]. Em sistemas de identificação automatizada (*AFIS*), a forma de representação das características extraídas é determinante para a taxa de acerto, escalabilidade e tempo de resposta.

Como capturas biométricas reais sofrem com rotação, translação, contato parcial, variações de pressão e ruídos severos, a extração de representações discriminativas e invariantes é indispensável. Métodos clássicos baseados nas localizações e orientação das minúcias (terminações e bifurcações de cristas), assim como em sua quantidade variável são eficazes em imagens nítidas, mas exigem emparelhamento geométrico de alto custo computacional [3, 4]. Modelos baseados em *Deep Learning* geram representações compactas de tamanho fixo, permitindo verificação em tempo real [1, 2].

MATERIAIS E MÉTODOS

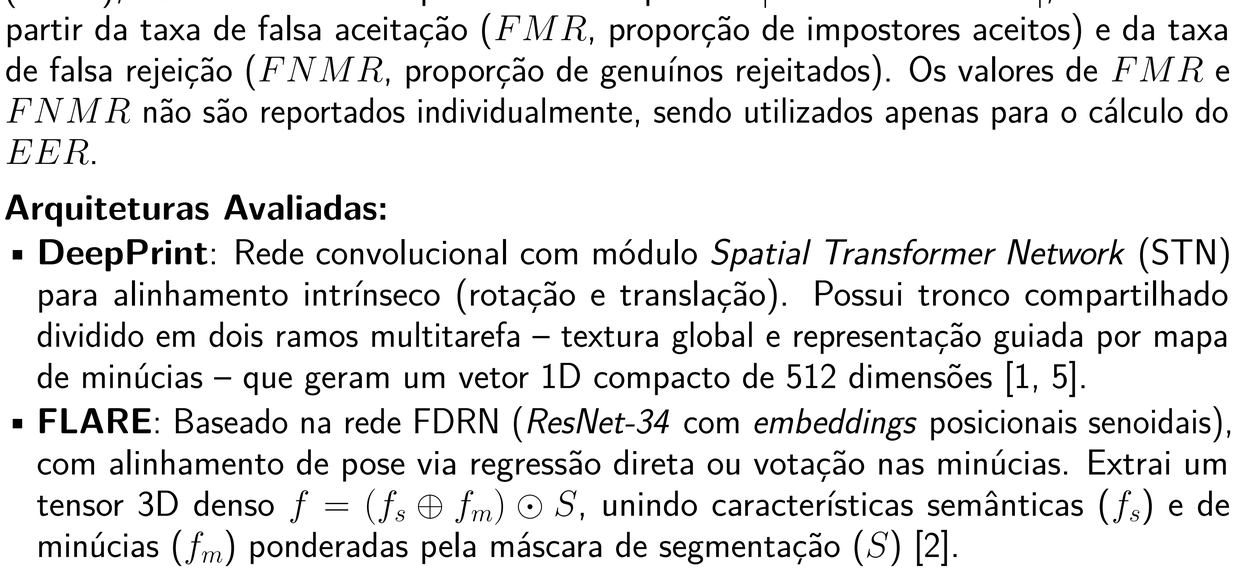
Bases de Dados: Foram utilizados os subconjuntos A e B das competições *Fingerprint Verification Competition* (FVC2000, FVC2002 e FVC2004) [6], que abrangem sensores ópticos, capacitivos e térmicos (DB1, DB2 e DB3) e geração sintética (DB4), com resoluções de 500 a 569 dpi e 800 imagens por base (100 dedos $\times$ 8 impressões). Adicionalmente, empregaram-se as bases ópticas da Neurotechnology (500 dpi) [7]: *CrossMatch* (408 imagens) [8] e *DigitalPersona U.are.U* (520 imagens).

Métricas Biométricas: A avaliação de verificação baseou-se na taxa de igual erro (EER), definida no limiar operacional em que $\min|FMR - FNMR|$, calculada a partir da taxa de falsa aceitação (FMR, proporção de impostores aceitos) e da taxa de falsa rejeição ($FNMR$, proporção de genuínos rejeitados). Os valores de FMR e $FNMR$ não são reportados individualmente, sendo utilizados apenas para o cálculo do EER.

Arquiteturas Avaliadas:

- **DeepPrint**: Rede convolucional com módulo *Spatial Transformer Network* (STN) para alinhamento intrínseco (rotação e translação). Possui tronco compartilhado dividido em dois ramos multitarefa – textura global e representação guiada por mapa de minúcias – que geram um vetor 1D compacto de 512 dimensões [1, 5].
- **FLARE**: Baseado na rede FDRN (*ResNet-34* com *embeddings* posicionais senoidais), com alinhamento de pose via regressão direta ou votação nas minúcias. Extrai um tensor 3D denso $f = (f_s \oplus f_m) \odot S$, unindo características semânticas (f_s) e de minúcias (f_m) ponderadas pela máscara de segmentação (S) [2].
- **MCC**: Método clássico que constrói cilindros 3D locais invariantes ao redor de cada minúcia extraída pelo *FingerNet*, discretizando a vizinhança espacial (x, y) e direcional (θ) para codificar a densidade relativa das minúcias adjacentes [3].

Realce de Cristas: Avaliaram-se os modelos *UNetEnh* (U-Net) e *PriorEnh* (difusão com prior de orientação), comparando o desempenho com e sem pré-processamento (Figura 2).



(a) DeepPrint $(3, 36\%)$ (b) FLARE Vot. $(0, 81\%)$ (c) MCC $(2, 69\%)$

(d) DeepPrint (PriorEnh) $(3, 31\%)$ (e) FLARE Vot. $(0, 12\%)$ (f) MCC $(2, 10\%)$

Figura 1: Pontuações de similaridade (Genuínos em verde vs. Impostores em vermelho) em DB1-A (a–c) e CrossMatch (d–f).

RESULTADOS E DISCUSSÕES

A Tabela 1 apresenta o desempenho em EER (%) dos métodos base (sem realce). Destaca-se a superioridade do **FLARE (Votação)**, com EER média geral de **0,64%**.

Tabela 1: EER (%) dos métodos base nos subconjuntos Parte A do FVC e bases da Neurotechnology.

Origem	Base	DeepPrint	FLARE (Reg.)	FLARE (Vot.)	MCC
FVC2000	DB1-A	3,36	0,81	0,81	2,69
	DB2-A	2,69	0,54	0,19	4,33
	DB3-A	3,85	0,63	0,59	10,21
Média FVC2000		**3,30**	**0,66**	**0,53**	**5,74**
FVC2002	DB1-A	5,20	0,44	0,25	–
	DB2-A	8,19	0,62	0,69	–
	DB3-A	8,51	3,32	2,08	–
Média FVC2002		**7,30**	**1,46**	**1,01**	**–**
FVC2004	DB1-A	17,05	0,25	0,24	–
	DB2-A	5,27	1,44	0,87	–
	DB3-A	4,91	0,38	0,31	–
Média FVC2004		**9,08**	**0,69**	**0,47**	**–**
Média FVC		**6,56**	**0,94**	**0,67**	**–**
Neurotech.	CrossMatch	3,31	0,49	0,12	2,10
	U.are.U	2,76	0,58	0,86	1,94
Média Neurotech.		**3,04**	**0,53**	**0,49**	**2,02**
Média Geral		**5,92**	**0,86**	**0,64**	**–**

A Figura 1 ilustra as pontuações de similaridade no FVC2000 DB1-A e CrossMatch. No FLARE, impostores (vermelho) concentram-se próximos a 0,2 e genuínos (verde) acima de 0,6. O MCC superou o DeepPrint em bases ópticas nítidas (2,02% vs. 3,04% na Neurotechnology), mas degradou sob ruído severo (10,21% no FVC2000 DB3-A).



(a) DB3-A (Orig.) (b) DB3-A (*PriorEnh*) (c) DB4-A (Sintética) (d) CrossMatch

Figura 2: Amostras: FVC2000 DB3-A original (a) e com *PriorEnh* (b), sintética DB4-A (c) e CrossMatch (d).

CONCLUSÕES

- O FLARE obteve desempenho superior em todos os cenários, retendo relações geométricas espaciais e suprimindo o fundo pela máscara de segmentação;
- O MCC teve alta acurácia em imagens ópticas nítidas, mas sua dependência de minúcias torna-o sensível à degradação;
- O DeepPrint proporcionou rápida verificação com vetores 1D compactos, porém apresentou maior sensibilidade a ruídos severos pela agregação global precoce;
- Os realces prévios (UNetEnh e PriorEnh) não geraram ganhos consistentes, evidenciando a robustez intrínseca das representações profundas.

AGRADECIMENTOS

Ao **Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq)**, pela bolsa de Iniciação Científica, e à **Universidade Federal do ABC (UFABC)**.

REFERÊNCIAS

[1] ENGELSMA, J. J. et al. Learning a fixed-length fingerprint representation. *IEEE TPAMI*, v. 43, n. 6, p. 1981–1997, 2021.
[2] Z. Pan, X. Guan, Y. Duan, J. Feng and J. Zhou, Fixed-Length Dense Fingerprint Representation With Alignment and Robust Enhancement, in IEEE Transactions on Information Forensics and Security, vol. 21, pp. 1751–1765, 2026.
[3] CAPPELLI, R. et al. Minutia Cylinder-Code: A New Representation and Matching Technique for Fingerprint Recognition. *IEEE TPAMI*, v. 32, n. 12, p. 2128–2141, 2010.
[4] MALTONI, D. et al. *Handbook of Fingerprint Recognition*. 2. ed. Springer, 2009.
[5] T. Rohwedder, D. Osorio-Roig, C. Rathgeb, and C. Busch, Benchmarking fixed-length Fingerprint Representations across different Embedding Sizes and Sensor Types, in Intl. Conf. of the Biometrics Special Interest Group (BIOSIG), Sep. 2023.
[6] MAIO, D. et al. FVC2000: Fingerprint Verification Competition. *IEEE TPAMI*, v. 24, n. 3, p. 402–412, 2002.
[7] NEUROTECHNOLOGY. VeriFinger SDK: Fingerprint demo databases. Disponível em: https://www.neurotechnology.com. Acesso em: 2025.
[8] NEUROTECHNOLOGY. CrossMatch Sample Database. Disponível em: https://www.neurotechnology.com/download.html. Acesso em: 2026.

Apoio:

XVI Encontro de Iniciação Científica
XIX Simpósio de Iniciação Científica da UFABC
21º Congresso de Iniciação Científica da USCS