AVALIAÇÃO DE TÉCNICAS DE EXTRAÇÃO DE CARACTERÍSTICAS PARA RECONHECIMENTO DE USUÁRIOS PELA IMPRESSÃO DIGITAL

Thiago Fernandes Dias[1,2], **Paulo Henrique Pisani**[1] (Orientador), **Francisco de Assis Zampirolli**[1] (Coorientador)

[1]Centro de Matemática, Computação e Cognição (CMCC) – Universidade Federal do ABC (UFABC)

[2]Bolsista de Iniciação Científica (CNPq) · Santo André – SP, Brasil

{thiago.dias, paulo.pisani, f.zampirolli}@ufabc.edu.br

OBJETIVOS

Este projeto tem como objetivo central **avaliar e comparar o desempenho de diferentes técnicas de extração de características para o reconhecimento de usuários pela impressão digital**. Os objetivos específicos compreendem:

- Avaliar arquiteturas de aprendizado profundo que extraem representações de tamanho fixo: vetorial unidimensional (*DeepPrint*) e tensorial tridimensional densa multitarefa (*FLARE*);
- Contrastar os resultados com a abordagem clássica baseada em minúcias locais (*Minutia Cylinder-Code* – MCC);
- Analisar o impacto de técnicas de pré-processamento e realce de cristas (*UNetEnh* e *PriorEnh*);
- Investigar a robustez dos modelos sob diferentes tecnologias de sensores (ópticos, capacitivos e térmicos) e sob ruídos severos.

INTRODUÇÃO

A biometria por impressões digitais baseia-se na singularidade e perenidade dos padrões de cristas e vales formados na epiderme das pontas dos dedos. Em sistemas de identificação automatizada (*Automated Fingerprint Identification Systems* – AFIS), a forma de representação das características extraídas é um dos fatores mais determinantes tanto para a taxa de acerto quanto para a escalabilidade e tempo de resposta.

Como capturas biométricas reais sofrem com rotação, translação, área de contato parcial, variações de pressão e ruídos severos de fundo, a extração de representações discriminativas e invariantes é indispensável. Historicamente, os métodos clássicos baseiam-se em minúcias (terminações e bifurcações de cristas). Embora acurados em imagens ópticas nítidas, exigem algoritmos de emparelhamento geométrico com elevado custo computacional. Recentemente, modelos profundos viabilizaram a geração de representações compactas de tamanho fixo, permitindo verificação em tempo real por métricas diretas de distância.

MATERIAIS E MÉTODOS

Bases de Dados Avaliadas: Foram utilizados os subconjuntos Parte A das competições *Fingerprint Verification Competition* (FVC2000, FVC2002 e FVC2004) com sensores reais (DB1, DB2 e DB3), totalizando 800 imagens por base (100 dedos $\times$ 8 impressões). Adicionalmente, empregaram-se as bases ópticas da Neurotechnology: *CrossMatch* (408 imagens) e *DigitalPersona U.are.U* (520 imagens).

Table 1: Especificação dos conjuntos de dados e tecnologias de sensores avaliados.

Conjunto	Base	Tecnologia do Sensor	Resolução	Dimensões
FVC2000	DB1-A	Óptico (Secure Desktop Scanner)	500 dpi	300×300
	DB2-A	Capacitivo (TouchChip)	500 dpi	256×364
	DB3-A	Óptico (DF-90)	500 dpi	448×478
FVC2002	DB1-A	Óptico (TouchView II)	500 dpi	388×374
	DB2-A	Óptico (FX2000)	569 dpi	296×560
	DB3-A	Capacitivo (100 SC)	500 dpi	300×300
FVC2004	DB1-A	Óptico (V300)	500 dpi	640×480
	DB2-A	Óptico (DigitalPersona U.are.U)	500 dpi	328×364
	DB3-A	Térmico (FingerChip)	500 dpi	300×480
Neurotech.	CrossMatch	Óptico (Verifier 300)	500 dpi	504×480
	U.are.U	Óptico (U.are.U 4000)	500 dpi	440×500

Métricas Biométricas: A avaliação utilizou as taxas de falsa aceitação (FMR), falsa rejeição ($FNMR$) e a taxa de igual erro (EER), calculada no ponto operacional de mínima diferença $|FMR - FNMR|$.

Arquiteturas Avaliadas:

- **DeepPrint**: Rede convolucional profunda (CNN) com módulo Spatial Transformer Network (STN) para alinhamento intrínseco. Extrai um vetor unidimensional compacto de 512 dimensões via aprendizado multitarefa.
- **FLARE**: Modelo baseado na arquitetura FDRN (ResNet-34 adaptada com embeddings posicionais senoidais). Extrai um descritor denso tridimensional $f = (f_s \oplus f_m) \odot S$, preservando relações geométricas espaciais e suprimindo o fundo pela máscara de segmentação S.
- **MCC**: Técnica clássica baseada em minúcias locais que constrói cilindros 3D discretizando a vizinhança espacial e angular, alimentada pelo extrator de minúcias *FingerNet*.

Métrica de Similaridade Cosseno Normalizada (FLARE):

$$M(q,g) = \frac{f_q'^T \cdot f_g'}{\|f_q \odot S_g\|_F \cdot \|f_g \odot S_q\|_F} \tag{1}$$

O numerador efetua o produto interno restrito às regiões válidas de primeiro plano, enquanto o denominador normaliza pela norma de Frobenius da intersecção espacial compartilhada entre a consulta (q) e a referência (g).

Modelos de Realce de Cristas: Foram avaliadas as técnicas *UNetEnh* (baseada em arquitetura U-Net para restauração de cristas) e *PriorEnh* (modelo generativo com prior de orientação de cristas e difusão), comparando os resultados obtidos com e sem realce.

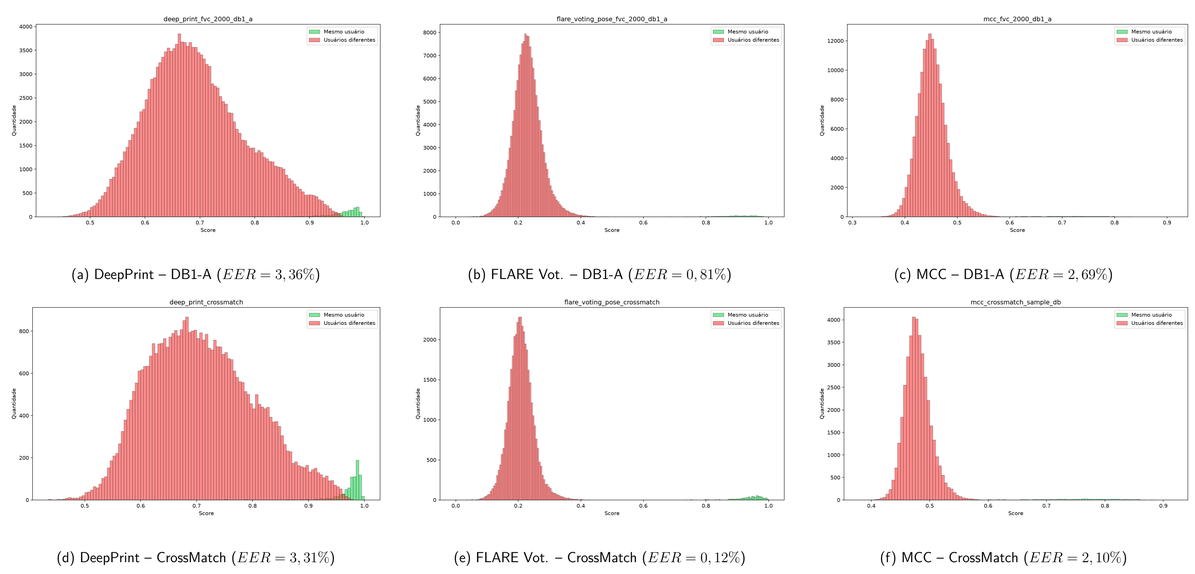
RESULTADOS E DISCUSSÕES

A Tabela 2 apresenta o desempenho comparativo em EER (%) dos métodos base (sem realce) em todos os conjuntos avaliados. Os resultados evidenciam a superioridade marcante do **FLARE (Votação)**, que obteve EER média geral de **0,64%**.

Table 2: EER (%) dos métodos base nos subconjuntos Parte A do FVC e bases da Neurotechnology.

Edição / Origem	Base	DeepPrint	FLARE (Reg.)	FLARE (Vot.)	MCC
FVC2000	DB1-A	3,36	0,81	0,81	2,69
	DB2-A	2,69	0,54	0,19	4,33
	DB3-A	3,85	0,63	0,59	10,21
Média FVC2000		**3,30**	**0,66**	**0,53**	**5,74**
FVC2002	DB1-A	5,20	0,44	0,25	–
	DB2-A	8,19	0,62	0,69	–
	DB3-A	8,51	3,32	2,08	–
Média FVC2002		**7,30**	**1,46**	**1,01**	–
FVC2004	DB1-A	17,05	0,25	0,24	–
	DB2-A	5,27	1,44	0,87	–
	DB3-A	4,91	0,38	0,31	–
Média FVC2004		**9,08**	**0,69**	**0,47**	–
Média FVC		**6,56**	**0,94**	**0,67**	–
Neurotechnology	CrossMatch	3,31	0,49	0,12	2,10
	U.are.U	2,76	0,58	0,86	1,94
Média Neurotechnology		**3,04**	**0,53**	**0,49**	**2,02**
Média Geral		**5,92**	**0,86**	**0,64**	–

A Figura 1 ilustra a distribuição das pontuações de similaridade para o subconjunto FVC2000 DB1-A e a base óptica CrossMatch. No FLARE, as pontuações de impostores (vermelho) concentram-se próximas a 0,2, enquanto usuários genuínos (verde) situam-se acima de 0,6, garantindo separação praticamente ideal. O MCC superou o DeepPrint em bases ópticas de alta qualidade (2,02% contra 3,04% na Neurotechnology e 2,69% no FVC2000 DB1-A), mas degradou acentuadamente em sensores ruidosos (10,21% no FVC2000 DB3-A).



(a) DeepPrint – DB1-A ($EER = 3,36\%$) (b) FLARE Vot. – DB1-A ($EER = 0,81\%$) (c) MCC – DB1-A ($EER = 2,69\%$)

(d) DeepPrint – CrossMatch ($EER = 3,31\%$) (e) FLARE Vot. – CrossMatch ($EER = 0,12\%$) (f) MCC – CrossMatch ($EER = 2,10\%$)

Figura 1: Distribuição das pontuações de similaridade (Genuínos em verde vs Impostores em vermelho) para FVC2000 DB1-A e Neurotechnology CrossMatch.

CONCLUSÕES

- O FLARE apresentou desempenho superior em todos os cenários avaliados, beneficiado pela retenção de relações geométricas espaciais e supressão explícita do fundo pela máscara de segmentação;
- O MCC exibiu excelente acurácia em impressões ópticas de alta qualidade, porém sua dependência estrita de minúcias torna-o vulnerável à degradação da imagem;
- O DeepPrint viabilizou alta velocidade de processamento com vetores 1D compactos, mas apresentou maior sensibilidade a ruídos severos devido à agregação global precoce;
- Etapas prévias de realce (UNetEnh e PriorEnh) não geraram aprimoramentos consistentes, evidenciando a robustez intrínseca das representações densas profundas.

AGRADECIMENTOS

O presente trabalho foi realizado com apoio financeiro do **Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq)** por meio de bolsa de Iniciação Científica, e da **Universidade Federal do ABC (UFABC)**.

REFERÊNCIAS

[1] ENGELSMA, J. J. et al. Learning a fixed-length fingerprint representation. *IEEE TPAMI*, v. 43, n. 6, p. 1981–1997, 2021.

[2] YU, Y. et al. Dense representation for robust fixed-length fingerprint matching. *IEEE TBIOM*, 2024.

[3] CAPPELLI, R. et al. Minutia Cylinder-Code: A new representation and matching technique. *IEEE TPAMI*, v. 32, n. 12, p. 2128–2141, 2010.

[4] MALTONI, D. et al. *Handbook of Fingerprint Recognition*. 2. ed. Springer, 2009.

[5] ROHWEDDER, T. DeepPrint: Evaluation of fixed-length fingerprint extractors. *Master's Thesis*, Hasso Plattner Institute, 2023.

Apoio:

UFABC USCS CNPq